

	grep/glob/read	和证据读取。
存储层	AGFS、VectorDB、RocksDB/ Milvus/VikingDB	提供持久化、索引和可部署扩展能力。

五、详细设计

5.1 模型与检索设计

- Embedding 模型：用于文档、图片摘要、FAQ、投标材料的向量化检索，当前配置支持火山引擎 Doubao embedding，也可替换为兼容模型。
- VLM/LLM：用于生成 L0 摘要、L1 概览、意图分析、问答生成、投标证据摘要和会话记忆提取。
- 检索策略：先通过语义和关键词定位高相关目录，再在目录内精细检索并读取原文，避免传统 RAG 只返回孤立切片。
- 可观察性：每个结果保留 viking:// URI、命中理由、层级、来源文档和必要图片，便于人工核验。

5.2 数据来源与预处理

数据类型	处理方式	典型用途
产品手册、FAQ、实施文档	解析为 Markdown/结构化目录，生成摘要和概览，建立索引。	客服问答、实施支持、售后自助。
历史工单、对话记录	按账号/用户隔离，抽取长期记忆和高频问题。	相似问题推荐、多轮对话连续性。
资质证书、授权资料、案例库	保留图片证据，支持证书优先排序和本地图片物化。	投标资格章节、商务证明材料。
技术方案、产品参数、架构图	文本与相关图片共同检索，输出可引用证据片段。	投标技术方案、售前方案初稿。
Skills 与 Prompt 模板	作为可复用技能挂载到知识库，供不同 Agent 调用。	客服话术、投标流程、审核标准。

5.3 与现有工作模式集成

1. 业务人员上传文档或指定资料目录，OpenViking 自动解析、生成摘要并建立索引。
2. 客服、售前、实施等角色通过 Web 页面、Bot、企业 IM 或 MCP 客户端调用同一知识库。
3. AI 输出带来源的回答、证据包或材料初稿，人工负责确认、修订和发布。
4. 会话结束后，系统将高价值问答、用户偏好和任务经验沉淀为长期记忆，进入下一轮复用。

5.4 安全与治理

- 账号、用户和资源空间隔离：支持 account_id、user_id、owner_space 等范围控制。
- 部署密钥集中配置：模型 API Key、root_api_key、public_bot secret 通过 ov.conf 管理。
- 人工接管与审核：客服场景保留人工接管，投标场景要求证据先行、人工定稿。
- 可追溯输出：所有关键材料输出都应保留来源 URI、引用证据和缺口说明。