

## 七、实现路径与部署说明

| 阶段          | 工作内容                                  | 交付物               |
|-------------|---------------------------------------|-------------------|
| 第 1 阶段：知识导入 | 整理客服 FAQ、产品手册、资质证书、案例库，导入 OpenViking。 | 可检索知识库、文档摘要、目录结构。 |
| 第 2 阶段：客服试点 | 接入 public_bot 与客服页面，选择典型问题集做命中率评估。    | 客服演示环境、问题集、召回报告。  |
| 第 3 阶段：投标试点 | 接入投标资料，按章节验证证据包和缺口识别。                 | 投标证据包、章节初稿、缺口清单。  |
| 第 4 阶段：产品化  | 沉淀模板、权限、监控、部署脚本与客户化配置。                | 可复制私有化部署方案。       |

| 部署项  | 建议配置                                                                                   |
|------|----------------------------------------------------------------------------------------|
| 运行方式 | Docker Compose 双容器：openviking-server 提供 HTTP API、admin、guest；vikingbot 提供 bot gateway。 |
| 端口   | OpenViking 默认 1933；VikingBot 默认 18790，容器网络内互通。                                         |
| 配置文件 | deploy/ov.conf：server、storage、embedding、vlm、bot、log 等配置集中管理。                           |
| 模型   | Embedding 与 VLM 默认可配置为火山引擎兼容模型，也可替换为企业认可的模型服务。                                         |
| 健康检查 | curl http://127.0.0.1:1933/health；bot 健康检查 /bot/v1/health。                             |

## 八、预期效果评估

| 维度    | 预期/已验证效果                                                                   | 度量指标                 |
|-------|----------------------------------------------------------------------------|----------------------|
| 效率提升  | 客服重复问题自动答复，投标材料检索从人工翻找变为分钟级证据收集。                                           | 平均响应时长、人工接管率、章节准备耗时。 |
| 质量提升  | 回答与投标材料带来源 URI 和证据，降低凭记忆编写导致的错误。                                           | 引用覆盖率、审核返工次数、缺口关闭率。  |
| 成本降低  | 上下文按 L0/L1/L2 分层按需加载，减少无效 token。                                           | 单次任务输入 token、模型调用成本。 |
| 创新价值  | 同一知识库可支撑客服、投标、法务、研发、HR 等多个 Agent。                                          | 新增应用接入数量、复用资料数量。     |
| 已验证数据 | LoCoMo10 评测中，OpenViking 方案任务完成率相对基线提升约 43% - 49%，输入 token 成本降低约 83% - 91%。 | README_CN 中实验记录。     |