

token 估算	CJK 字符约 0.7 token，其他非空白字符约 0.3 token	用于分片决策，不等同于模型 tokenizer 精确计数。
PREVIEW_ORDER_FILENAME	.preview-order.json	记录生成的 markdown_paths，便于预览和顺序恢复。

PDF/Office 如何进入分片

PDF 解析会尽量通过书签或字体分析识别标题，并把标题注入为 Markdown heading；Word、Excel、PowerPoint 等办公文档会先转换为可读文本/表格结构，再进入统一的分片与树构建逻辑。