

2.1 分片配置与常量

配置/常量	当前口径	说明
ParserConfig.max_section_size	默认 1000 tokens	超过后触发分片；MarkdownParser 内部兜底常量为 1024。
DEFAULT_MIN_SECTION_TOKENS	512 tokens	小于该值的章节优先合并，避免碎片过小影响检索。
ParserConfig.max_section_chars	默认 6000 字符	硬性字符上限，防止 token 估算误差导致超大文件。
token 估算	CJK 字符约 0.7 token，其他非空白字符约 0.3 token	用于分片决策，不等同于模型 tokenizer 精确计数。
PREVIEW_ORDER_FILENAME	.preview-order.json	记录生成的 markdown_paths，便于预览和顺序恢复。

PDF/Office 如何进入分片

PDF 解析会尽量通过书签或字体分析识别标题，并把标题注入为 Markdown heading；Word、Excel、PowerPoint 等办公文档会先转换为可读文本/表格结构，再进入统一的分片与树构建逻辑。