


2. 分片机制详细说明

分片决策流程图



原则：OpenViking 优先保持文档自然层级，不做固定长度硬切；分片结果直接影响 L2 内容、L0/L1 摘要和检索路径。

OpenViking 的分片发生在 Parser 阶段。它不是按固定字符长度粗暴切块，而是先尽量把不同来源转换成 Markdown/文本结构，再根据标题层级、章节长度、段落边界和字符上限生成目录树与 L2 内容文件。TreeBuilder 不负责切分，只负责把 Parser 产生的临时树落到最终 URI。

判断条件	处理方式	输出形态
文档较小	估算 token <= max_section_size，且字符数 <= max_section_chars	保存为单个 L2 文件
无标题的大文档	按空行分段，累计 token/字符超过限时切分	{文档名}_1.md、{文档名}_2.md...
有标题的大文档	识别最高层标题作为一级分片，保留标题层级	标题对应文件或目录
章节有子标题	父章节成为目录，直接内容作为虚拟 section，子标题继续递归	目录 + 子文件/子目录
小章节	小于 DEFAULT_MIN_SECTION_TOKENS，进入 pending，和相邻小节合并	merged 或 {first}_{count}more 文件
超大章节且无子标题	按段落切分；单段过长时按 max_section_chars 强制切	{章节名}_1.md、{章节名}_2.md...
文件名过长或重复	sanitize 后截断，并用 hash 后缀保证唯一	稳定、可落盘的 URI segment

配置/常量	当前口径	说明
ParserConfig.max_section_size	默认 1000 tokens	超过后触发分片；MarkdownParser 内部兜底常量为 1024。
DEFAULT_MIN_SECTION_TOKENS	512 tokens	小于该值的章节优先合并，避免碎片过小影响检索。
ParserConfig.max_section_chars	默认 6000 字符	硬性字符上限，防止 token 估算误差导致超大文件。