



# OpenViking 通用 AI 知识库底座

赋能智能客服与智能投标的可复用上下文数据库方案

第二届西软 AI 提效大赛参赛材料

| 项目     | 内容                                      |
|--------|-----------------------------------------|
| 推荐赛道   | 赛道二：客户 AI 赋能；同时兼具赛道一内部提效价值              |
| 参赛作品形态 | AI 应用解决方案 + 可运行知识库底座 + 客服机器人案例 + 智能投标案例 |
| 提交阶段   | 报名/初赛材料初稿                               |
| 建议团队   | 研发、实施、客服、售前/投标联合组队；成员信息待填写              |
| 版本日期   | 2026 年 5 月                              |

## 一句话定位

以 OpenViking 为通用 AI 知识库与上下文数据库底座，把企业分散的文档、经验、资质、案例和会话记忆组织成可检索、可观察、可复用的 AI 能力层，并通过智能客服与智能投标验证落地价值。

# 一、参赛定位与材料要求映射

本项目建议以“客户 AI 赋能”赛道参赛：OpenViking 本身不是单一客服机器人，而是可复用的企业 AI 知识库底座。客服机器人是已落地的成功场景，智能投标是同一底座向售前与交付场景扩展的第二个高价值应用。该定位更符合大赛强调的“优秀作品转化为可复用产品或解决方案”的目标。

| 官方材料要求  | 本材料对应内容                | 完成状态 |
|---------|------------------------|------|
| 项目背景    | 第二章：业务痛点、影响、AI 解决原因    | 已覆盖  |
| 目标设定    | 第三章：可衡量目标与验证方法         | 已覆盖  |
| 解决方案概述  | 第四章：总体架构、数据流、工作流       | 已覆盖  |
| 详细设计    | 第五章：模型、数据、检索、集成、安全     | 已覆盖  |
| 预期效果评估  | 第八章：效率、质量、成本、推广价值      | 已覆盖  |
| 部署/技术文档 | 第七章与附录：部署路径、配置、接口、测试   | 已覆盖  |
| 商业价值分析  | 第九章概要；另有独立商业价值报告       | 已覆盖  |
| 演示视频    | 另有《演示视频脚本》文档，控制在 5 分钟内 | 已覆盖  |

# 二、项目背景

酒店、景区、文旅和企业服务场景中，知识密集型工作正在快速增加：客户咨询依赖产品手册和 FAQ，实施交付依赖历史工单和操作经验，售前投标依赖资质证照、产品方案、案例资料和交付证据。传统知识库通常停留在“文档存储 + 关键词搜索”层面，难以直接成为 AI 应用可用的上下文。

| 核心问题    | 业务影响                            | 为什么适合用 AI 解决                                    |
|---------|---------------------------------|-------------------------------------------------|
| 知识碎片化   | 资料分散在文档、网盘、聊天记录、工单和个人经验中，复用成本高。 | 大模型擅长理解自然语言，但需要稳定、可追溯、结构化的上下文输入。                |
| 检索命中不稳定 | 传统 RAG 扁平切片容易丢失目录语义，回答缺少全局背景。   | OpenViking 用文件系统范式和目录递归检索，让 AI 先定位知识区域，再深入读取证据。 |
| 材料生产重复  | 客服答复、投标章节、方案说明大量重复劳动，且质量依赖个人经验。 | AI 可基于统一知识库生成初稿、引用证据并暴露缺口，把人工精力转向审核和决策。         |
| 结果难以审计  | AI 回答如果没有来源和检索轨迹，业务团队不敢直接使用。    | OpenViking 保留 URI、检索路径和证据包，便于追溯、纠错和持续优化。        |

# 三、目标设定

目标分为两类：一类是已有项目资料可以支撑的技术验证目标，另一类是参赛演示与后续试点中建议量化跟踪的业务目标。为避免夸大，本方案将“已验证数据”和“试点目标”分开表述。

| 目标类别 | 量化目标 | 验证方式 |
|------|------|------|
|------|------|------|

|              |                                                                 |                                 |
|--------------|-----------------------------------------------------------------|---------------------------------|
| 已验证：上下文效果    | 在公开评测记录中，OpenViking 结合 OpenClaw 后任务完成率相对原生记忆提升约 43% - 49%。      | 基于项目 README_CN 中 LoCoMo10 评测记录。 |
| 已验证：Token 成本 | 同一评测中输入 token 成本相对原生记忆降低约 83% - 91%，相对 LanceDB 方案降低约 92% - 96%。 | 基于项目 README_CN 中实验组对比。          |
| 初赛演示目标       | 5 分钟内展示一个知识库底座支撑两个应用：客服问答与投标证据收集。                               | 演示视频脚本按 0:00 - 5:00 编排。         |
| 客服试点目标       | 知识沉淀完成后，重复咨询人工处理时间目标降低 30% - 50%，常见问题自助命中率目标达到 60% 以上。          | 通过客服日志、人工接管率、问题命中率统计。           |
| 投标试点目标       | 资质/方案/案例检索从人工翻找缩短到分钟级，投标材料初稿准备时间目标降低 40% 以上。                    | 通过章节证据收集耗时、返工次数和人工审核意见统计。       |

## 四、解决方案概述

### 核心思路

把 OpenViking 建设为“企业 AI 大脑的上下文层”：资源、记忆、技能统一进入 VikingFS；系统自动生成 L0/L1/L2 三层上下文；检索时结合目录定位、语义搜索、关键词匹配和证据读取；上层应用通过 Agent 工具或 MCP 接口复用同一知识库。

企业文档 / FAQ / 工单 / 资质证书 / 案例库 / 会话记录



Parser 文档解析与结构化



VikingFS 分层组织：Resources / Memories / Skills



L0 摘要 + L1 概览 + L2 原文内容



Dense + Sparse 索引，目录递归检索，可视化检索轨迹



Agent 工具 / MCP / HTTP API



西软 AI 客服 | 智能投标助手 | 更多垂直 AI 应用

## 4.1 架构分层

| 层级  | 组件                                              | 作用                            |
|-----|-------------------------------------------------|-------------------------------|
| 应用层 | 西软 AI 客服、智能投标助手、VikingBot                       | 面向业务用户提供问答、证据收集、材料生成、人工接管等能力。 |
| 服务层 | OpenViking Server、Session Manager、Tool Registry | 提供 API、会话记忆、工具编排、权限和多租户隔离。    |
| 知识层 | VikingFS、L0/L1/L2、URI                           | 将企业知识按文件系统方式组织，保留目录语义和来源。     |
| 检索层 | Dense + Sparse、目录递归检索、grep/glob/read            | 兼顾语义相似、关键词精确、路径定位和证据读取。       |
| 存储层 | AGFS、VectorDB、RocksDB/Milvus/VikingDB           | 提供持久化、索引和可部署扩展能力。             |

# 五、详细设计

## 5.1 模型与检索设计

- Embedding 模型：用于文档、图片摘要、FAQ、投标材料的向量化检索，当前配置支持火山引擎 Doubao embedding，也可替换为兼容模型。
- VLM/LLM：用于生成 L0 摘要、L1 概览、意图分析、问答生成、投标证据摘要和会话记忆提取。
- 检索策略：先通过语义和关键词定位高相关目录，再在目录内精细检索并读取原文，避免传统 RAG 只返回孤立切片。
- 可观察性：每个结果保留 viking:// URI、命中理由、层级、来源文档和必要图片，便于人工核验。

## 5.2 数据来源与预处理

| 数据类型               | 处理方式                             | 典型用途            |
|--------------------|----------------------------------|-----------------|
| 产品手册、FAQ、实施文档      | 解析为 Markdown/结构化目录，生成摘要和概览，建立索引。 | 客服问答、实施支持、售后自助。 |
| 历史工单、对话记录          | 按账号/用户隔离，抽取长期记忆和高频问题。            | 相似问题推荐、多轮对话连续性。 |
| 资质证书、授权资料、案例库      | 保留图片证据，支持证书优先排序和本地图片物化。          | 投标资格章节、商务证明材料。  |
| 技术方案、产品参数、架构图      | 文本与相关图片共同检索，输出可引用证据片段。           | 投标技术方案、售前方案初稿。  |
| Skills 与 Prompt 模板 | 作为可复用技能挂载到知识库，供不同 Agent 调用。      | 客服话术、投标流程、审核标准。 |

## 5.3 与现有工作模式集成

1. 业务人员上传文档或指定资料目录，OpenViking 自动解析、生成摘要并建立索引。
2. 客服、售前、实施等角色通过 Web 页面、Bot、企业 IM 或 MCP 客户端调用同一知识库。

- 3. AI 输出带来源的回答、证据包或材料初稿，人工负责确认、修订和发布。
- 4. 会话结束后，系统将高价值问答、用户偏好和任务经验沉淀为长期记忆，进入下一轮复用。

5.4 安全与治理

- 账号、用户和资源空间隔离：支持 account\_id、user\_id、owner\_space 等范围控制。
- 部署密钥集中配置：模型 API Key、root\_api\_key、public\_bot secret 通过 ov.conf 管理。
- 人工接管与审核：客服场景保留人工接管，投标场景要求证据先行、人工定稿。
- 可追溯输出：所有关键材料输出都应保留来源 URI、引用证据和缺口说明。

六、核心落地案例

6.1 西软 AI 客服

当前项目已经包含“西软 AI 客服”公共测试页与知识召回测试能力。客服机器人可基于产品文档、FAQ 和历史工单回答用户问题，在无法确认时引导人工接管，并将对话沉淀为可复用记忆。

| 功能   | 说明                                  | 业务价值             |
|------|-------------------------------------|------------------|
| 文档问答 | 基于产品手册和 FAQ 进行精准回答。                 | 减少重复咨询，提高一线响应速度。 |
| 召回测试 | 通过 Recall Test 页面检查文档、摘要、命中分数和检索结果。 | 让知识库调优有依据，不再靠感觉。 |
| 多轮记忆 | 会话记录可提交到 OpenViking，形成长期上下文。        | 支持连续服务，减少用户重复描述。 |
| 匿名访客 | 支持 public_bot 配置，适合客户试用或公开演示。       | 降低试点门槛，便于业务推广。   |

6.2 智能投标助手

智能投标场景验证了 OpenViking 不是只服务客服问答的单点应用，而是能为复杂知识工作提供“证据检索 + 缺口识别 + 初稿生成”的通用底座。项目中已经提供投标材料服务、Agent 工具和 MCP Server。

| 工具/接口                            | 能力                     | 输出                                 |
|----------------------------------|------------------------|------------------------------------|
| search_certificates              | 搜索营业执照、资质证书、授权资料等证据。   | 带图片的证据项和来源 URI。                    |
| search_solution_materials        | 搜索方案、产品参数、案例和架构资料。     | 摘录、相关图片和可引用 Markdown。              |
| collect_bid_evidence             | 按投标章节需求收集证据并识别缺口。      | EvidencePack、claims coverage、gaps。 |
| openviking_read/search/list/glob | 开放底层文件系统检索能力给外部 Agent。 | 可被 Hermes、Codex 等 MCP 客户端复用。       |

## 七、实现路径与部署说明

| 阶段          | 工作内容                                  | 交付物               |
|-------------|---------------------------------------|-------------------|
| 第 1 阶段：知识导入 | 整理客服 FAQ、产品手册、资质证书、案例库，导入 OpenViking。 | 可检索知识库、文档摘要、目录结构。 |
| 第 2 阶段：客服试点 | 接入 public_bot 与客服页面，选择典型问题集做命中率评估。    | 客服演示环境、问题集、召回报告。  |
| 第 3 阶段：投标试点 | 接入投标资料，按章节验证证据包和缺口识别。                 | 投标证据包、章节初稿、缺口清单。  |
| 第 4 阶段：产品化  | 沉淀模板、权限、监控、部署脚本与客户化配置。                | 可复制私有化部署方案。       |

| 部署项  | 建议配置                                                                                   |
|------|----------------------------------------------------------------------------------------|
| 运行方式 | Docker Compose 双容器：openviking-server 提供 HTTP API、admin、guest；vikingbot 提供 bot gateway。 |
| 端口   | OpenViking 默认 1933；VikingBot 默认 18790，容器网络内互通。                                         |
| 配置文件 | deploy/ov.conf：server、storage、embedding、vlm、bot、log 等配置集中管理。                           |
| 模型   | Embedding 与 VLM 默认可配置为火山引擎兼容模型，也可替换为企业认可的模型服务。                                         |
| 健康检查 | curl http://127.0.0.1:1933/health；bot 健康检查 /bot/v1/health。                             |

## 八、预期效果评估

| 维度    | 预期/已验证效果                                                                   | 度量指标                 |
|-------|----------------------------------------------------------------------------|----------------------|
| 效率提升  | 客服重复问题自动答复，投标材料检索从人工翻找变为分钟级证据收集。                                           | 平均响应时长、人工接管率、章节准备耗时。 |
| 质量提升  | 回答与投标材料带来源 URI 和证据，降低凭记忆编写导致的错误。                                           | 引用覆盖率、审核返工次数、缺口关闭率。  |
| 成本降低  | 上下文按 L0/L1/L2 分层按需加载，减少无效 token。                                           | 单次任务输入 token、模型调用成本。 |
| 创新价值  | 同一知识库可支撑客服、投标、法务、研发、HR 等多个 Agent。                                          | 新增应用接入数量、复用资料数量。     |
| 已验证数据 | LoCoMo10 评测中，OpenViking 方案任务完成率相对基线提升约 43% - 49%，输入 token 成本降低约 83% - 91%。 | README_CN 中实验记录。     |

## 九、商业价值分析概要

对于客户 AI 赋能赛道，OpenViking 的商业价值不止于“做一个机器人”，而是把客户的业务知识资产转化为可运营、可复用、可审计的 AI 能力。独立商业价值分析报告已按官方规范另行整理。

| 价值方向  | 说明                                             |
|-------|------------------------------------------------|
| 客户价值  | 7x24 智能服务、知识复用、投标/售前效率提升、经验沉淀。                 |
| 目标客户  | 酒店集团、景区、文旅综合体、系统集成客户、内部售前与客服团队。                |
| 收益模式  | 知识库底座、AI 客服模块、投标助手模块、私有化部署、运维服务。               |
| 竞争优势  | Agent-native 上下文数据库、目录递归检索、三层上下文、MCP 兼容、证据可追溯。 |
| 推广可行性 | 已有 Docker 部署、客服页面、投标 MCP 工具和可验证评测数据。           |

## 十、风险与应对

| 风险     | 影响             | 应对策略                              |
|--------|----------------|-----------------------------------|
| 资料质量不齐 | 回答不完整或投标证据不足。  | 导入前清洗资料；输出 gaps 缺口清单；建立知识维护机制。    |
| 模型幻觉   | 误答或生成不可靠材料。    | 强制来源引用；客服低置信度转人工；投标由人工定稿。         |
| 权限与隐私  | 不同客户/部门资料混用。   | 多租户隔离、账号空间隔离、密钥和日志治理。             |
| 推广阻力   | 业务人员担心替代或使用复杂。 | 以“辅助和提效”定位，提供简单 Web/Bot 入口和可解释证据。 |
| 成本波动   | 模型调用成本不可控。     | 分层上下文、缓存、按需读取、灰度使用。               |

## 十一、演示与提交计划

- 报名阶段：提交报名表、本方案文档初稿、项目简介。
- 初赛阶段：补充演示视频链接与提取码，视频控制在 5 分钟内。
- 决赛阶段：准备 15 分钟现场演示，按“底座能力 + 客服案例 + 投标案例 + 商业价值”讲述。
- 建议演示数据：选择 3 - 5 份产品资料、2 - 3 个客服高频问题、1 个投标章节需求、若干资质/方案证据。

### 最终建议

参赛叙事不要只讲“客服机器人”，而要讲“一个通用知识库底座如何快速孵化多个 AI 应用”。这更贴合创新性、实用性、可推广性三项高权重评分维度。

## 附录：源码与材料依据

| 依据                 | 位置/说明                                                                                         |
|--------------------|-----------------------------------------------------------------------------------------------|
| OpenViking 定位与核心能力 | README_CN.md、DESIGN_DOC.md                                                                    |
| L0/L1/L2 与目录递归检索   | README_CN.md、docs/zh/concepts/03-context-layers.md、07-retrieval.md                            |
| 客服机器人              | bot/README_CN.md、admin/src/pages/TestBot.tsx、RecallTest.tsx                                   |
| 智能投标工具             | bot/vikingbot/services/bid_material.py、agent/tools/bid_material.py、mcp/bid_material_server.py |
| 部署方式               | deploy/README.md、deploy/docker-compose.yml、deploy/ov.conf.example                             |
| 大赛要求               | 第二届西软 AI 大赛方案.docx、第二届西软 AI 大赛提交文档规范说明.docx                                                   |